

Міністерство освіти і науки України
Національний технічний університет України
«Київський політехнічний інститут імені Ігоря Сікорського»

Інститут прикладного системного аналізу
Кафедра математичних методів системного аналізу

Звіт

про виконання лабораторної роботи №3
з дисципліни “Розпізнавання образів”

Виконали:
Студенти 4 курсу
Групи КА-76 і КА-72
Борбела Артур
Фалілеєва Дар’я

Київ – 2020

Завдання

2) Маючи досягнення з попередньої серії, докрутити до лаби **класифікатор** на ваш особистий смак, натренувати його на ваш об'єкт (або ж якщо є час і натхнення то на інший), за необхідності розширюючи вибірку, і на об'єкт сусіда з таким же класифікатором на основі алгоритмів отримання характеристик зображення. Після того зробити дві речі: прогнати отримане комбо з класифікатора і дескриптора на тестовій вибірці збираючи як позитивні результати так і помилки першого і другого роду та замірюючи швидкодію; і записати демонстраційне відео з вашим об'єктом та згодувати його цьому ж комбо записуючи у окремий файл результат роботи (скажімо те ж відео з текстовим оверлеєм). Далі знаючи особливості вашого дескриптора колективно з кимсь у кого такий же класифікатор проаналізувати особливості класифікатора в комбінації з вашими дескрипторами. Бонусні очки за використання кількох класифікаторів (видів класифікаторів) і/або запис відео з візуалізацією процесу розпізнавання/детекції.

Обмеження таке ж як в попередній лабі, пари алгоритмів мають бути унікальними в кожній команді. Команди в тому ж файлику, що й на попередню лабу, в іншій вкладці.

Докрутити алгоритм класифікації напряду до ключових точок ми не можемо.

1) оскільки кількість їхня різна а масив вхідних параметрів повинен бути для класифікатора однакової довжини.

2) ми можемо рахувати їхню кількість але це приведе до того ж результату що й в попередній роботі.

Вихід генерувати ключові точки й не матчити його з оригіналом, а спробувати їх кластеризувати розраховуючи на те що деякий кластер (або декілька схарактеризує нам шуканий об'єкт) тобто в нас буде масив довжина якого рівна кількості кластерів X_{train} .

Після того як ключові точки зібранні по кластерам ми маємо задати єдине значення для кластера (число а не масив точок) нам нічого не остається окрім взяти середня значення для координат цих ключових точок даного кластера.

Тобто на вхід нашому класифікатору будемо подавати дані в вигляді

```
X_train      [9.10000000e+01      8.26666667e+01      7.80000000e+01  
8.40000000e+01  
5.00000000e+01 9.20000000e+01 1.27000000e+02 4.30000000e+01  
1.16000000e+02 4.40000000e+01]  
Y_train [1, 0, 0, 1, 0, 1, 1, 1]
```

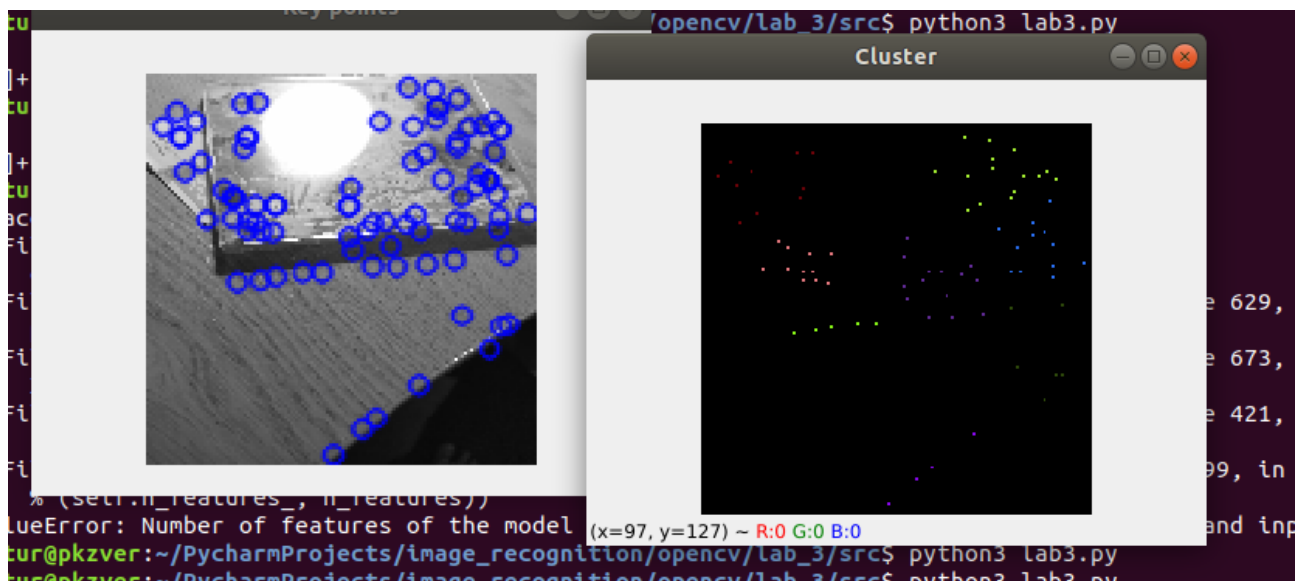
Для кластеризації був вибран алгоритм

```
from sklearn.cluster import Kmeans
```

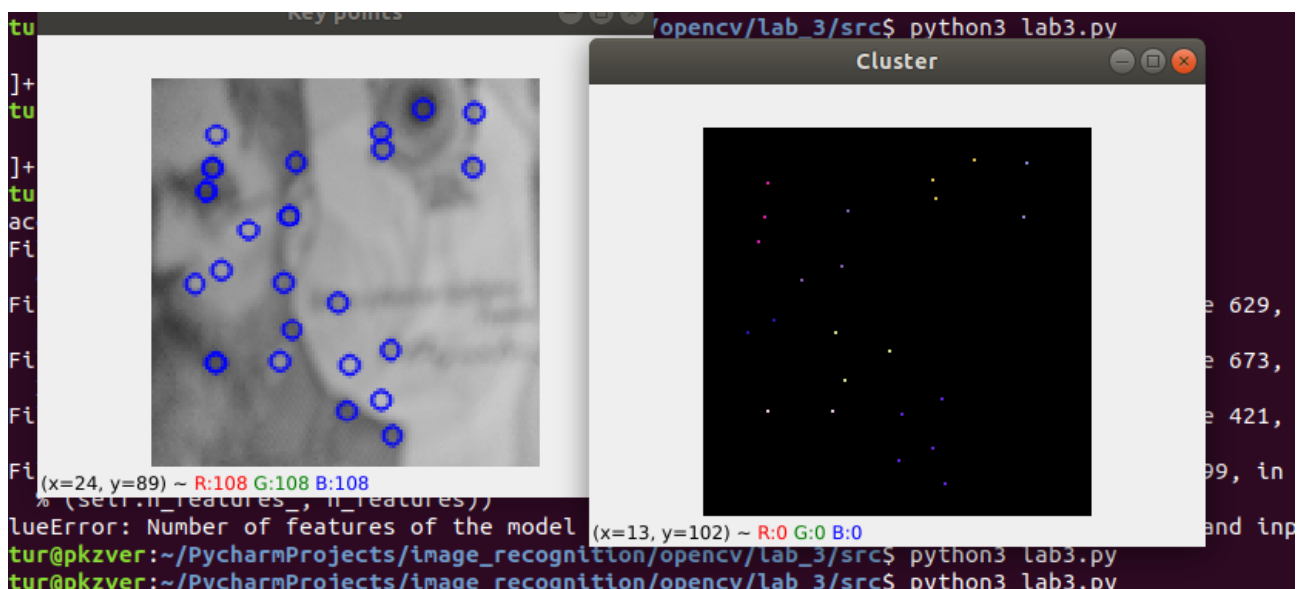
Перша проблема була в тому що для різних датасетів потрібно було різне значення кластерів

Наприклад для першого датасету ключові точки можна було з лехкістю розбити на 8 кластерів.

SIFT

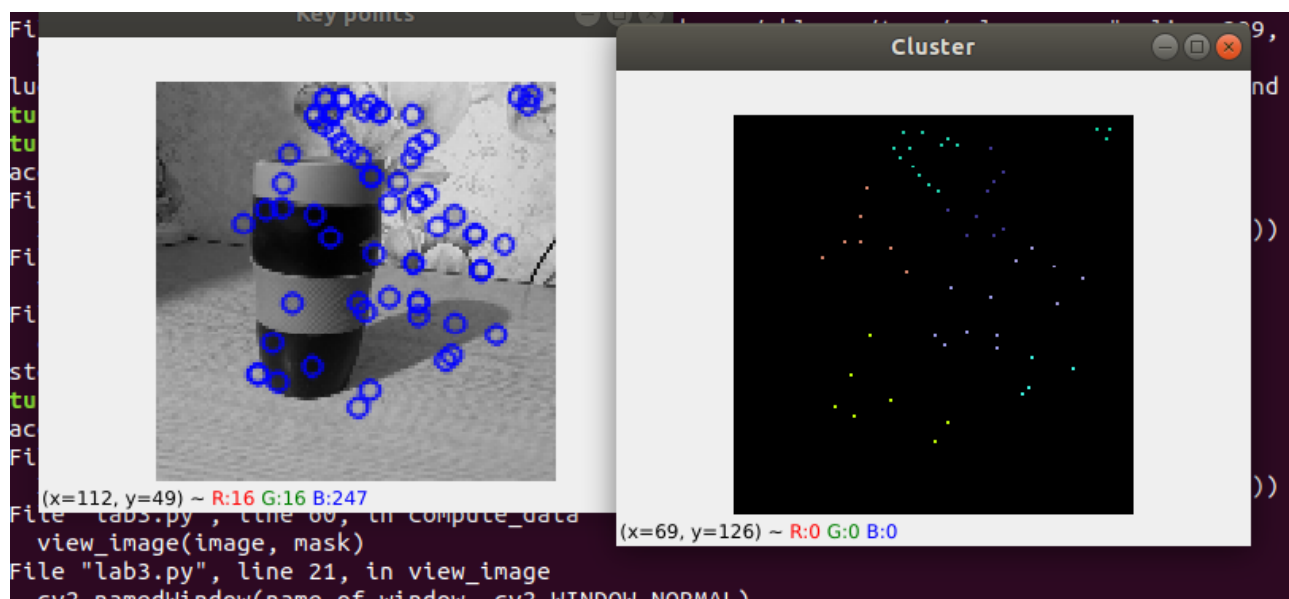


ORB

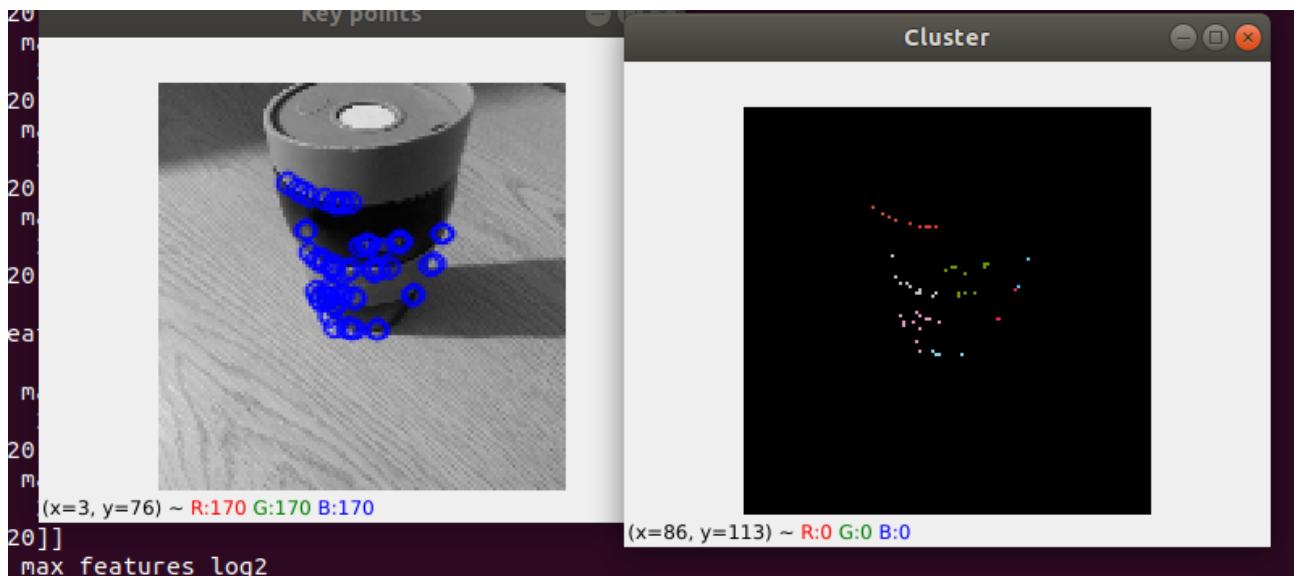


А для другого датасету це виявилось набагато складніше

SIFT



ORB



Причина цьому генерація малої кількості ключових точок

Яка при поцесі кластеризації отримувала

ConvergenceWarning: Number of distinct clusters (6) found smaller than n_clusters (8). Possibly due to duplicate points in X.

Дуже інформативний warning який виявився повідомленням про те що в даному випадку кластеризувати на вказану певну кластерів алгоритм не може що в подальшому зашкоджує логіці алгоритм. (той випадок коли в нас 8 кластерів і 8 точок і одна з них майже повністю наложується на іншу). Прийшлося вибирати оптимальне число кластерів при якому я втрачав найменше фотографій з датасету 2. Оптимальна кількість кластерів вийшла 8 (при ній я втрачав лише 3 фотографії з дескриптором SIFT, для ORB все було краще)

Для алгоритму класифікації був вибран

```
from sklearn import ensemble RandomForestClassifier
```

(тому що вже був певний досвід роботи з ним)

Для налаштування параметрів алгоритму класифікації була вибрана метрика

```
from sklearn.metrics import confusion_matrix
```

Параметри класифікації

Параметр `max_depth` — визначає максимальну глибину дерева. Тобто при задачі класифікації вибірка об'єктів розділяється по певному критерію поки елементи в листі дерева не будуть належати до одного класу, що спричиняє перенавчання (RandomForest дуже схильний до перенавчання) параметр `max_depth` задає зупинку розбиття, тобто після кількох ітерацій розбиття закінчується.

`Min_samples_split` параметр який задає мінімальну кількість розбиття.

`Max_features` (за замовчуванням = «auto»)(auto))

Кількість функцій які потрібно врахувати при пошуці кращого розбиття

- Якщо «auto», то `max_features=sqrt(n_features)`.
- Якщо «sqrt», то `max_features=sqrt(n_features)`.
- Якщо «log2», то `max_features=log2(n_features)`.
- Якщо немає то `max_features=n_features`.

Оскільки RandomForest має схильність до перенавчання велике значення `max_depth`, `Min_samples_split` погано сказується на тестову оцінку.

Тренувальна вибірка для кращого аналізу роботи класифікатора була двох видів (тестова так же само)

- 1) 29% - wrong data; 71% - correct data
- 2) 60% - wrong data; 40% - correct data

Дані знаходяться в файлі randomForestClassifier.txt

Приклад

// DATASET_1 ORB X_train: 29% - wrong data; 71% - correct data

Max_depth

Param max_depth 1

[[1 3]

[9 15]]

Param max_depth 2

[[2 1]

[8 17]]

Param max_depth 3

[[2 2]

[8 16]]

Param max_depth 4

[[2 2]

[8 16]]

Param max_depth 5

[[2 2]

[8 16]]

Param max_depth 6

[[2 2]

[8 16]]

Param max_depth 7

[[2 2]

[8 16]]

Param max_depth 8

[[2 3]

[8 15]]

Param max_depth 9

[[2 3]

[8 15]]

Param max_depth 10

[[2 3]

[8 15]]

Param max_depth 11

[[2 3]

[8 15]]

Param max_depth 12

[[2 3]

[8 15]]

Param max_depth 13

[[2 3]

[8 15]]

Param max_depth 14

[[2 3]

[8 15]]

Param max_depth 15

[[2 3]

[8 15]]

Param max_depth 16

[[2 3]

[8 15]]

Param max_depth 17

[[2 3]

[8 15]]

Param max_depth 18

[[2 3]

[8 15]]

Param max_depth 19

[[2 3]

[8 15]]

Max_features

Param max_features auto

[[2 3]

[8 15]]

Param max_features sqrt

[[2 3]

[8 15]]

Param max_features log2

[[2 3]

[8 15]]

Min_samples_split

Param min_samples_split 0.1

[[2 2]

[8 16]]

Param min_samples_split 0.2

[[2 4]

[8 14]]

Param min_samples_split 0.3

[[2 3]

[8 15]]

Param min_samples_split 0.4


```
[[ 2 3]
 [ 8 15]]
Param min_samples_split 0.5
[[ 1 3]
 [ 9 15]]
Param min_samples_split 0.6
[[ 1 3]
 [ 9 15]]
Param min_samples_split 0.7
[[ 0 0]
 [10 18]]
Param min_samples_split 0.8
[[ 0 0]
 [10 18]]
Param min_samples_split 0.9
[[ 0 0]
 [10 18]]
```

Confusion_matrix[0][0] — правильно выбрано wrong data
Confusion_matrix[0][1] — помилка першого роду
Confusion_matrix[1][0] — помилка другого роду
Confusion_matrix[1][1] — правильно выбрано correct data

При тренувальному наборі 29% - wrong data; 71% - correct data

Найкращий показник для ORB

DATASET_1

```
[[ 2 2]
 [ 8 16]]
```

DATASET_2

[[7 5]

[2 15]]

З певного порога min_samples_split 0.7

[[0 0]

[9 20]]

[[0 0]

[10 18]] — що значно гірше оскільки алгоритм завжди каже correct data (із-за перенавчання) хоч accuracy_score більше

Найкращий показник для SIFT

DATASET_1

[[0 2]

[9 17]]

DATASET_2

[[1 1]

[4 23]]

З певного порога в нього також сама проблема як і в ORB

При тренувальному наборі : 60% - wrong data; 40% - correct data

Найкращий показник для ORB

DATASET_1

[[26 3]

[1 14]]

DATASET_2

[[22 3]

[2 17]]

Найкращий показник для SIFT

DATASET_1

[[20 6]

[6 12]]

DATASET_2

[[19 4]

[4 17]]

Аналізуючи даний результат можна сказати що класифікатор працює але такий результат являється поганим. Якщо його перенавчити то він тупо вказує на щось одне типу такий предмет є.

Параметри для класифікатора які виявились найкращими це
min_samples_split 0.3 ; max_depth=5;

ORB для всіх випадків виявився дещо кращим за SIFT. Що в принципі можна пояснити тим що обидва дескриптора генерували багатенько ключових точок (в попередній роботі SIFT добре матчився а ORB ні).

accuracy_score, f1_score , recall_score — можна було для статистики теж вивести але confusion_matrix дає найкраще представлення оскільки данні метрики генеруються на основі неї.

Тестова вибірка в мене була 20% тому що це такий певно мовити баланс, оскільки чим більше ми витрачаєм на навчальну вибірку тим модель краще працює але постає проблема неточного результату на

тестовій вибірці. Впринципі завжди сходяться до того що 80/20 краще співвідношення.

Про залежність від вмісту на фотографії:

Розмитість, затемненість та всі інші фактори які були порівнянні в попередній роботі тут також грають важливу роль. Ці негативні фактори(освітленість, розмитість) безпосередньо погано впливають на обидва дескриптора.(Тепер чим більше ключових точок згенерує дескриптор тим більша ймовірність що даний предмет розпізнється). Відповідно якщо є негативні фактори то ключових точок генерується набагато менше.

З попередньої роботи відомо що ORB відпрацьовує набагато швидше за SIFT, із-за цього можна сказати що перемога на користь ORB. Тому що головною вимогою до обох цих дескрипторів є генерування однакової кучності ключових точок на один і той самий предмет в незалежності від інших факторів а чи будуть вони матчитись в нас не грає ролі.

Тому для аналізу відео використовував ORB.

Аналіз часових даних

Дані знаходяться в файлі time.txt

Аналіз відео можна розбити на декілька етапів:

- 1) робота ORB (генерування ключових точок)
- 2) робота Kmeans кластирезація цих ключових точок
- 3) робота натренованого вже RandomForestClassifier

Заміри часу

Для кожного датасету окремо

Замір часу виконувався з кожного знімку (1 секунда відео = 10 знімків)

а) // DATASET_* ORB X_train: 29% - wrong data; 71% - correct data (замір сумісного часу на всіх трьох етапах)

б) // DATASET_* ORB X_train: 29% - wrong data; 71% - correct data PREDICT TIME (замір часу третього етапу)

в) // DATASET_* ORB X_train: 29% - wrong data; 71% - correct data HIST TIME
(замір сумісного часу першого і другого етапу)

г) // DATASET_* ORB X_train: 29% - wrong data; 71% - correct data KMEANS TIME
(замір часу другого етапу)

Почнемо з другого датасету (відео з кружкою)

Час “а” кожного знімку в ньому коливався

0.0407557487487793
0.03990745544433594
0.0400998592376709
0.038005828857421875
0.03813457489013672
0.03831744194030762
0.03751373291015625
0.03948020935058594

Лиш тільки деякі з них були

0.05646061897277832

Але вони були поодинокі й важливої ролі не грали.

Дослідивши всі наступні виміри (б, в, г)

Можна зробити висновки

- час “б” для всіх знімків майже однаковий однаковий => робота натренованого вже RandomForestClassifier не як не грає на час.

-час “в” для всіх знімків однаковий але подекуди є викиди подібно до сумісного, для з'ясування появи цих викидів був заміряний час “г”

=> який виявився без них з цього можна було зробити висновок що на час роботи головну роль відіграє дескриптор

Для першого датасету (відео з купюрою) все виявилось набагато цікавіше в ньому середній час

0.06576871871948242
0.05914115905761719
0.0534820556640625
0.06487751007080078
0.07110404968261719
0.06177091598510742


Та були перепади

0.009548187255859375
0.010381698608398438
0.010675907135009766
0.00977635383605957
0.01018977165222168
0.014444351196289062
0.011078834533691406
0.009372949600219727
0.0112152099609375
0.011574506759643555
0.011237859725952148

Аналізуючи заміри “б”, “в”, “г” прийшов до висновку що й в другому датасеті => дескриптор відіграє важливу роль на час.

Далі спробував відслідити що було зображено на відео в ті періоди.

Цими знімками виявилось зображення столу без всяких інших предметів.



З цього робимо висновки: на швидкість алгоритму саме більше впливає дескриптор і його природа генерування ключових точок, що навіть можна зрозуміти візуально порівнявши два відео співставивши їх з часом “а”

(Тобто на кадрі багато різних предметів => час роботи дескриптора більше)

З відео Датасету 1 бачимо, що при швидкому пересуванні і показу частини предмета на 1 с дескриптор розпізнає предмет, але при цьому чомусь класифікує ноутбук, простирадло, стіл як наш предмет

З відео Датасету 2 бачимо, що при масштабуванні, зміні ракурсу, коливанні предмета та збільшенні освітлення – дескриптор не розпізнає предмет, але при перекриванні рукою частини предмета – дескриптор розпізнає предмет.

Тож, можемо зробити висновок, що дескриптор відмінно працює в умовах частини зображення, його коливання, швидкого пересування, але програє в умовах поганого освітлення та зміни ракурсу предмета.

Відео знаходяться в папці src

Із-за політики гітхаба друге відео знаходиться в гугл диску [ссылку на нього](#) буде в листі.